

МИНОБРНАУКИ РОССИИ ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «ВОРОНЕЖСКИЙ
ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ» (ФГБОУ ВО «ВГУ»)

ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК
КАФЕДРА ТЕХНОЛОГИЙ ОБРАБОТКИ И ЗАЩИТЫ ИНФОРМАЦИИ

Разработка системы классификации изображений на основе онтологий и методов машинного обучения

Обучающийся: Филозоп С.А., студентка 4 курса

Руководитель: Борисова А.А., к.и.н., доцент

I.O Постановка задачи

Проблема

- Обработка больших объемов неструктурированных данных
- Трудности с семантической совместимостью и контекстным пониманием

Цель исследования

Практическое применение онтологий в **автоматической классификации изображений** с использованием нейронных сетей и семантического представления знаний

Задачи

- Изучение существующих способов классификации изображений
- Внедрение онтологий
- Совместное использование нейросетей и онтологии
- Оценка точности и эффективности классификации

Ключевое замечание

Онтологии выступают в качестве посредников между пользователями и информационными системами, обеспечивая создание единых логически непротиворечивых систем знаний, которые объединяют экспериментальные данные с экспертными знаниями в предметной области

1.1 Формальное определение онтологий

Формальное определение

Онтология формально представляется в виде упорядоченной тройки:

$$O = \langle T, R, F \rangle$$

T Классы и концепции	R Отношения между классами	F Функции интерпретации
--------------------------------	--------------------------------------	-----------------------------------

Основные элементы

- 1 Классы**
Общие типы объектов (например, «Транспортное средство», «Животное»)
- 2 Экземпляры**
Конкретные элементы (например, «Поезд», «Лошадь»)
- 3 Семантические отношения**
is_a, part_of, regulates, causes

Основные преимущества

- 1. Уникальные идентификаторы для сущностей**
- 2. Проверка согласованности и обнаружение ошибок**
- 3. Возможность автоматического вывода новых правил**
- 4. Семантическая совместимость между системами**

2.0 Практическая реализация: архитектура системы

Полный рабочий процесс системы

1

Получение изображений

COCO датасет с автоматической разметкой сцен

2

Детекция объектов

Модель YOLOv8n (80 классов объектов)

3

Построение онтологии

Автоматизированная онтология на основе правил из классов YOLO

4

Классификация

Различные подходы: baseline, ontology, hybrid, ML

Цель системы: Создать масштабируемую систему, которая анализирует изображения и классифицирует их на основе визуального контента с высокой точностью и полнотой

Целевые категории сцен



Restaurant



Store



Office



Street



Home

Dataset

1500 изображений (300 на категорию)
из датасета COCO со
сбалансированным представлением
для объективной оценки

2.1 Построение онтологии и обнаружение объектов

Модель YOLOv8

Архитектурные особенности

- Обнаружение без привязки
- Модуль C2f (улучшенный C3)
- Усовершенствованная аугментация данных
- Улучшенный механизм слияния признаков

Классы объектов

80

Категорий, охватывающих транспортные средства, животных, мебель, бытовую технику, спортивное оборудование

Принцип семантической избыточности

Большинство сцен описываются несколькими объектами, что обеспечивает устойчивость классификации к ошибкам обнаружения

Построение онтологии

Семантические правила

Сопоставление классов YOLO с категориями сцен

Пример: [traffic light, stop sign, car] → Street

Ключевые объекты против обычных

Ключевой: высокая разрешающая способность (traffic light → street)

Обычный: встречается в разных сценах (chair, person)



2.2 Интеграционные подходы

1 Baseline

Голосование по большинству

Ограничения

- Жесткое соответствие «один к одному» между объектом и сценой
- Игнорирует семантическую значимость
- Отсутствует обработка комбинаций

2 Ontology

Вывод на основе правил с приоритетом ключевых объектов

Двухэтапный процесс:

1. Проверка ключевых объектов (confidence = 1.0)
2. Оценка охвата для сопоставления правил

3 Гибридный подход

Каскадная интеграция: онтология для уверенных случаев, ML для сложных

Логика:

Если достоверность онтологии $\geq 0,8 \rightarrow$ использовать её

В противном случае $\rightarrow$ использовать ML модель

4 ML + Onto Features

Обогащенные векторы признаков, сочетающие обнаружение с семантическими знаниями

Категории функций:

- Корреляция
- Иерархия
- Контекст

Последовательность: Каждый подход основывается на предыдущем, добавляя семантическую глубину и повышая точность классификации за счет более глубокой интеграции онтологии и машинного обучения

3.0 Пример работы

I Детекция объектов



Обнаруженные объекты: traffic light, car, fire hydrant, person

2 Онтологические признаки

Coverage: Street = [**car**, bus, truck, motorcycle, bicycle, **traffic light**, stop sign, parking meter] = $2/8 = 0.25$

Co-occurrence: TrafficPattern = [**traffic light**, stop sign, **car**, bus, truck] = $2/5 = 0.40$

Hierarchy: Vehicle = [**car**, bus, truck, motorcycle, bicycle] = 1

Context:

traffic light $\rightarrow 3$

car $\rightarrow 2$

Street = $3 + 2 = 5$


Key Object: Street_Key = [**traffic light**, stop sign] = 1

3 ML + Onto Features

Вектор признаков (YOLO + Ontology Features) $\rightarrow$ Random Forest / XGBoost $\rightarrow$ Street

3.1 Результаты эксперимента: сравнительный анализ

Сравнение точности (12 методов)



Лучший результат

90.98%

XGB + Onto Features

Qwen2-VL

87.64%

XGB


86.47%

RF + Onto Features

84.59%

3.2 Оценка производительности и показатели эффективности

Сравнение эффективности (12 методов)



Оценка эффективности

Нормализованная точность:

$$A_{\text{norm}} = (A - A_{\text{min}}) / (A_{\text{max}} - A_{\text{min}})$$

Нормализованная скорость:

$$S_{\text{norm}} = (S_{\text{max}} - S) / (S_{\text{max}} - S_{\text{min}})$$

Интегральная метрика эффективности ($\alpha = 0.7$):

$$E = (\alpha \cdot A_{\text{norm}} + (1 - \alpha) \cdot S_{\text{norm}}) \times 100\%$$

Лучший результат

99.7%

XGB + Onto Features

Выводы

Основные выводы

- Онтологии значительно улучшают обработку данных благодаря семантической совместимости
- Гибридная система успешно сочетает нейронные сети с онтологическим мышлением
- Глубокая интеграция за счет обогащения функций превосходит поверхностные гибридные подходы

Ключевой вывод

Онтологии позволяют сосредоточиться на **глубинных закономерностях**, минимизировать требования к ресурсам и сделать анализ более интерпретируемым

Возможности системы

1. Точность классификации 90.98%

XGB + Onto Features

2. Многоуровневый механизм

Приоритет ключевых объектов, выделение контекста, гибридный каскад

3. Эффективность классификации

Эффективность 99.7% для XGB + Onto Features

Дальнейшие исследования

- Добавление категорий сцен
- Классификация видео
- Интеграция в приложение камеры

МИНОБРНАУКИ РОССИИ ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «ВОРОНЕЖСКИЙ
ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ» (ФГБОУ ВО «ВГУ»)

ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК
КАФЕДРА ТЕХНОЛОГИЙ ОБРАБОТКИ И ЗАЩИТЫ ИНФОРМАЦИИ

Разработка системы классификации изображений на основе онтологий и методов машинного обучения

Обучающийся: Филозоп С.А., студентка 4 курса

Руководитель: Борисова А.А., к.и.н., доцент